

数据预处理

数据清洗

1. 删去Cabin, Ticket
2. 平均值填充Age

特征工程

1. 将SibSp与Parch合并为同行人数Companion, 并增加Isalone列 $Companion = 1 + SibSp + Parch$
2. 将Age, Fare归一化
3. Pclass做one hot处理
4. Sex做one hot处理
5. 众数填充缺失, Embarked做one hot处理
6. 提取称呼, 并删去Name

ps:原本想用不同性别, 仓位, 港口的存活率来代替非数值型的特征, 但是感觉这样做就失去了训练模型来预测的意义, 毕竟这样的话这几个量就与是否存活强相关了, 模型可能会只关注这几个量, 所以采用了onehot

ps:最初直接把Name这一列删去了, 但在后期改进时, 通过问ai了解到称呼其实很重要, 故增加了这一列, 在结果中有标出 (这一部分因为统计整个891条数据太麻烦, 所以求助了ai)

分层抽样

按照8: 1: 1划分了训练集, 验证集与测试集, 并使三组中生还的比例接近原数据集

ps:最初采用的是随机取样, 但这样抽出来的结果会使得训练结果方差极大, 所以换成了分层抽样

模型搭建

模型选择

逻辑回归模型处理二分类任务 激活函数: sigmoid 损失函数: 二元交叉熵损失 优化算法: SGD(小批量随机梯度下降)

超参数设置

epoch = 2000 学习率0.01时震荡, 故设置为0.001 模型在最初训练时发现到末尾时验证集准确率下降, 有过拟合的倾向, 故采用正则化与早停 正则化设置为L2 patience: 30 min_delta = 0.001

结果

多次更换种子后, 发现模型在最终测试集的准确率为0.7640~0.8764之间

改进的想法

ps:当前是初版的模型，之后有时间会再次改进

采用k折交叉验证 加入新的神经层与激活函数，使模型不再线性